

Validity and Reliability of Instrument

Sawaeng Watcharathanakij Ph.D.

Introduction to Research Instruments

- Core Purpose: Research conclusions are only as strong as the instruments used to collect data.
- The Goal: Ensure measurements are accurate (valid) and consistent (reliable).
- Scope: Applies to surveys, questionnaires, psychological tests, clinical assays, and observational rubrics.


Validity vs. Reliability

Validity (Accuracy):

- *Definition:* The degree to which an instrument measures what it purports to measure.
- *Key Question:* "Are we measuring the correct target variable?"


Reliability (Consistency):

- *Definition:* The degree to which an instrument yields stable, repeatable results under unchanged conditions.
- *Key Question:* "If we repeat the measurement, will we get the same result?"



The Target Analogy (Visual Concept)

- **High Reliability, Low Validity:** Darts land tightly clustered, but far off the target center (consistently wrong).
- **Low Reliability, High Validity:** Darts scatter broadly around the target center (accurate on average, but noisy).
- **High Reliability, High Validity (Ideal):** Darts land tightly clustered directly in the bullseye.
- **Takeaway:** Reliability is *necessary* for validity, but reliability alone *does not guarantee* validity.



Major Types of Instrument Validity

Face Validity (Surface Review):

- Subjective evaluation of whether items look appropriate to respondents/non-experts.
- Testing: Pilot testing, participant feedback on readability and format.

Content Validity (Domain Representation):


- Assesses whether items comprehensively cover all dimensions of the construct domain.
- Testing: Expert panel review, calculation of Content Validity Index (CVI).



Construct Validity (Theoretical Fit):

- Assesses how well the operationalized items align with underlying theoretical constructs.
- Testing: Exploratory/Confirmatory Factor Analysis (EFA/CFA), Multitrait-Multimethod Matrix (MTMM).


Criterion Validity (External Benchmark):

- 
- Compares instrument results against a gold-standard external criterion.
 - Concurrent Validity: Instrument vs. current benchmark measured simultaneously.
 - Predictive Validity: Instrument vs. future outcome (e.g., SAT scores predicting GPA).

Multitrait-Multimethod Matrix (MTMM)

- **Purpose:** Advanced statistical framework designed by Campbell & Fiske to evaluate **Construct Validity**.
- **Core Components:**
 - **Convergent Validity (Monotrait-Multimethod):** Measures the *same trait* using *different methods*. Scores should correlate highly.
 - **Discriminant Validity (Heterotrait-Multimethod):** Measures *different traits* using *different methods*. Scores should show low or no correlation.
- **Why Use MTMM?** Isolates true construct variance from method-induced variance/bias.

VALIDATING CONSTRUCTS USING MULTI-TRAIT MULTI-METHOD



1. กำหนดคุณลักษณะที่ต้องการวัด (3 Traits)

- Trait A: ทักษะการสื่อสาร (Communication Skill)
- Trait B: ความคิดสร้างสรรค์ (Creativity)
- Trait C: การทำงานร่วมกับผู้อื่น (Teamwork)

2. กำหนดวิธีการประเมิน (3 Methods)

- Method 1: แบบประเมินตนเอง (Self-Report Questionnaire)
- Method 2: การสัมภาษณ์โดยหัวหน้างาน (Supervisor Interview)
- Method 3: การสังเกตพฤติกรรมขณะทำงานจริง (Behavioral Observation)



- ความเที่ยงตรงแบบลู่เข้า (Convergent Validity):
 - ตัวอย่าง: คะแนน ทักษะการสื่อสาร (Trait A) ที่ประเมินด้วยแบบประเมินตนเอง (Method 1) ควรมีความสัมพันธ์สูงกับคะแนนทักษะการสื่อสาร (Trait A) ที่ประเมินด้วยการสังเกตพฤติกรรม (Method 3)
 - สรุป: วัดคุณลักษณะเดียวกัน แม้ใช้วิธีต่างกัน ผลลัพธ์ต้องไปในทิศทางเดียวกัน
- ความเที่ยงตรงแบบจำแนก (Discriminant Validity):
 - ตัวอย่าง: คะแนนทักษะการสื่อสาร (Trait A) ที่มาจากการสัมภาษณ์ (Method 2) ควรมีความสัมพันธ์ต่ำกว่า เมื่อเทียบกับคะแนนความคิดสร้างสรรค์ (Trait B) ที่มาจากการสัมภาษณ์ (Method 2) เดียวกัน
 - สรุป: วัดคนละคุณลักษณะ แม้ใช้วิธีการประเมินเดียวกัน ผลลัพธ์ต้องแยกออกจากกันได้ ไม่ปะปนกัน

Single-Item vs. Multi-Item Measurement

Single-Item Instruments (Epidemiology / Macrosociology):

- *When to Use:* Concrete, observable, or double-concrete singular variables (e.g., age, income, smoking status, overall health).
- *Advantages:* Reduces respondent fatigue, increases completion rates in large cohort studies.

Multi-Item Instruments (Psychometrics / Behavioral Sciences):

- *When to Use:* Abstract, multi-dimensional, unobservable latent constructs (e.g., depression, job Satisfaction, extraversion).
- *Advantages:* Cancels out individual item noise, covers multidimensional aspects of psychological traits.

Types of Instrument Reliability

Test-Retest Reliability (Temporal Stability):


- Administers the exact same questionnaire to the same sample at two different time points.
- Metric: Pearson correlation, Intraclass Correlation Coefficient (ICC).



Inter-Rater Reliability (Observer Consistency):

- Measures agreement across different observers scoring the same subject or event.
- Metric: Cohen's Kappa (), Fleiss' Kappa, Weighted Kappa.

Internal Consistency (Item Homogeneity):

- 
- Assesses how closely linked items within a multi-item scale are to one another.
 - Metric: Cronbach's Alpha (), McDonald's Omega ()

Reliability Metrics in Epidemiological Research

Focus in Epidemiology:

- Reproducibility and classification agreement (Exposed vs. Unexposed; Case vs. Control) rather than scale internal consistency.

Common Statistical Metrics:

- Categorical / Binary Data: Cohen's Kappa (for moderate agreement, for strong agreement).
- Continuous / Quantitative Data: Intraclass Correlation Coefficient ().
- Triangulation: Self-report questionnaire data compared against electronic health records or biological biomarkers (e.g., cotinine levels for smoking).

Cronbach's Alpha (α)

Interpretation Benchmarks

- $\alpha \geq 0.9$: Excellent reliability (ideal for diagnostic or clinical decision tools).
- $\alpha \geq 0.8$: Good reliability (standard target for academic survey instruments).
- $\alpha \geq 0.7$: Acceptable threshold for exploratory research scales.
- $\alpha < 0.6$: Unacceptable reliability; requires item removal, rephrasing, or structural redesign.

Threats to Validity and Reliability

Threats to Validity:

- Ambiguous question wording and double-barreled items.
- Social desirability bias and halo effects.
- Selection/Sampling bias and unmeasured confounding variables.

Threats to Reliability:

- Survey length causing respondent fatigue or "straight-lining."
- Unstandardized test administration environments.
- Subjective or poorly defined scoring rubrics for raters.



Best Practices for Instrument Development Framework

Define Constructs:

- Establish theoretical boundaries using systematic literature reviews.

Draft & Expert Panel Review:

- Verify Face and Content Validity via Subject Matter Experts (SMEs).

Pilot Testing:

- Run preliminary trials on a representative sub-sample to assess item comprehension and initial reliability (α/κ).

Statistical Refinement:

- Perform factor analysis, remove non-performing items, and standardize administration protocols.

ประเด็น	วิจัยทางระบาดวิทยา (Epidemiology)	วิจัยด้านจิตวิทยา/สังคมศาสตร์ (Psychometrics)
ลักษณะตัวแปร	ตัวแปรชัดเจน/รูปธรรม (Concrete) เช่น การสูบบุหรี่, การป่วย	ตัวแปรแฝง/นามธรรม (Latent Construct) เช่น ภาวะซึมเศร้า, ทักษะคิด
เครื่องมือที่ใช้	คำถามเดียว (Single-Item Question)	แบบวัดหลายข้อคำถาม (Multi-Item Scale)
ดัชนีวัด Reliability	Cohen's Kappa (K) / ICC (Test-Retest)	Cronbach's Alpha (α) (Internal Consistency)
ดัชนีวัด Validity	Sensitivity & Specificity (เทียบกับผลตรวจจริง)	Factor Analysis / MTMM (Convergent/Discriminant)

Exploratory vs. Confirmatory Factor Analysis

- Exploratory Factor Analysis (EFA) — EFA ใช้ในระยะ "บุกเบิก/สร้างเครื่องมือ" เมื่อผู้วิจัยยังไม่ทราบโครงสร้างที่แน่ชัด หรือต้องการสำรวจว่าข้อถามที่มีอยู่จับกลุ่มกันได้อีกกี่องค์ประกอบ (Dimensions/Factors)
- วัตถุประสงค์หลัก: สกัดกลุ่มตัวแปร (Data Reduction) และค้นหาโครงสร้างแฝง (Latent Structure) จากข้อมูลเชิงประจักษ์

ขั้นตอนการนำเสนอผล EFA:

- การตรวจสอบความเหมาะสมของข้อมูล:
- KMO (Kaiser-Meyer-Olkin): ควรมีค่า ≥ 0.70 (หาก < 0.50 ถือว่าข้อมูลไม่เหมาะกับการทำ EFA)
- Bartlett's Test of Sphericity: ต้องมีนัยสำคัญทางสถิติ ($p < .05$) ยืนยันว่าข้อมูลมีความสัมพันธ์กันพอที่จะจัดกลุ่ม
- การคัดเลือกองค์ประกอบ (Factor Extraction & Rotation):
- Eigenvalue: คัดเลือกองค์ประกอบที่มีค่า Eigenvalue > 1.0 หรือพิจารณาจาก Scree Plot (จุดหักมุมของกราฟ)
- Factor Loading (น้ำหนักองค์ประกอบ): ข้อถามที่ดีควรมีค่า Factor Loading ≥ 0.40 หรือ 0.50 ขึ้นไป และไม่มีปัญหา Cross-loading (โหลดข้ามไปองค์ประกอบอื่นเกิน 0.30)

- Confirmatory Factor Analysis (CFA) — การวิเคราะห์องค์ประกอบเชิงยืนยัน CFA ใช้ในระยะ "ทดสอบทฤษฎี/ตรวจสอบเครื่องมือ" เมื่อผู้วิจัยมีกรอบทฤษฎีหรือผล EFA อยู่แล้ว และต้องการยืนยันว่าข้อมูลเชิงประจักษ์ใหม่ "ฟิต" (Fit) กับโมเดลตามทฤษฎีหรือไม่
- วัตถุประสงค์หลัก: ยืนยันโครงสร้างโมเดล และทดสอบความตรงเชิงคู่เข้า (Convergent Validity) และความตรงเชิงจำแนก (Discriminant Validity)

ดัชนีวัดความสอดคล้อง (Fit Index)	สัญลักษณ์	เกณฑ์ที่ยอมรับว่าโมเดลสอดคล้อง (Good Fit)
Relative Chi-Square	χ^2/df	<3.00 (หรือ <5.00 สำหรับกลุ่มตัวอย่างใหญ่)
Comparative Fit Index	CFI	≥ 0.95 (ยอมรับได้ที่ ≥ 0.90)
Tucker-Lewis Index	TLI	≥ 0.95 (ยอมรับได้ที่ ≥ 0.90)
Root Mean Square Error of Approximation	RMSEA	<0.06 (ยอมรับได้ที่ <0.08)
Standardized Root Mean Square Residual	SRMR	<0.08

ประเด็น	Exploratory Factor Analysis (EFA)	Confirmatory Factor Analysis (CFA)
จุดมุ่งหมาย	สำรวจและค้นหาโครงสร้างองค์ประกอบจากข้อมูล	ยืนยันสมมติฐาน/ทฤษฎีโครงสร้างที่มีอยู่แล้ว
ทฤษฎีชี้นำ	ไม่จำเป็นต้องมีโมเดลล่วงหน้า (Data-driven)	ต้องมีโมเดลและทฤษฎีรองรับชัดเจน (Theory-driven)
ข้อกำหนดข้อถาม	ข้อถามทุกข้อสามารถโหลดไปได้ทุกองค์ประกอบ	กำหนดให้ข้อถามโหลดเฉพาะองค์ประกอบที่ทฤษฎีระบุ
ดัชนีชี้วัดหลัก	KMO, Bartlett's Test, Eigenvalue, Factor Loadings	Fit Indices (χ^2/df , CFI, TLI, RMSEA), CR, AVE
ช่วงการวิจัย	พัฒนาแบบวัด / บุกเบิกตัวแปรใหม่	ตรวจสอบคุณภาพแบบวัด / ทดสอบทฤษฎีเชิงโครงสร้าง